Group 8 项目完成计划

CSI 436/536 Project P Learning with Pretrained Representations

成员 Yuhan Sun · Zeyu Pan · Jiayu Liao
更新日期 2026 年 10 月 20 日

当前阶段：期中材料和 pilot 实验已完成。接下来需要完成完整语料实验、稳健性检查、错误分析及期末交付。

本计划建议用约 14 个工作日完成主线。以下日程为工作量安排；课程截止日期和期末展示时长以最新通知为准。

已完成的工作

模块	已核实进度	剩余工作
数据	原始 11,871 句，清理后 11,559 句；完成文档分组及精确重复处理	完整语料划分审计与近重复检查
方法与实验	五种方法；1,500 训练 / 400 验证 / 600 测试；75 次 pilot 评估	最终协议下的主实验和对照
工程与诊断	模型版本、缓存、预测及图表已保存；4 项测试和 75 次结果审计通过；10 组句子对	通用审计、系统错误分析及全新环境复现
材料与代码	6 页期中 PPT、单页报告、讲稿、HTML 指南；GitHub 已上传	期末报告、PPT 和最终代码包

进度口径：文件生成并检查不代表已经向老师提交。当前 full 结果指 1,500 句 pilot 训练池；完整语料实验尚未运行。

最终研究问题与任务范围

在生物医学否定与推测提示词检测中，冻结的预训练表征在什么训练预算下更有帮助？结论在不同文档划分和类别比例下是否稳定？

主任务使用 no_cue、negation_only、speculation_only 三类真实标注。no_cue 不能解释为患者肯定患病。疾病实体状态及未见疾病泛化需额外可靠标注。

现有观察：每类 100 句时 BioBERT + LR 的 macro-F1 为 67.8% ± 1.1%；完整 pilot 训练池上 TF-IDF + SVM 为 84.3%。两种设置的类别比例不同，仍需对照分析。

固定协议与完成主实验

阶段 1 第 1 至 2 天 固定最终协议

- 新建最终实验配置，解除训练与测试的 pilot 数量上限，验证集保持 400 句；保留原 pilot 配置和结果。
- 固定方法、预算、种子、C 搜索范围和主要指标。训练前检查近重复句及模板，必要时重新分组并记录版本。
- 将 audit_results.py 从只读取 pilot 改为按配置审计，并检查实验矩阵是否完整；确认缓存创建、失败提示及重跑行为在新环境中有效。

验收：最终配置、样本和文档组数量已记录；不同方法使用相同训练 ID；缺失实验可被审计发现；新增结果写入独立目录。

核心实验设置

项目	计划设置
方法	TF-IDF + LR；TF-IDF + Linear SVM；BERT、BioBERT、PubMedBERT 冻结表征 + LR
训练预算	每类 10 / 25 / 50 / 100 句，另报完整训练池；平衡预算与完整池分开展示
模型选择	仅在验证集选择 C，范围 0.1 / 1 / 10；测试集用于最终评估
重复与指标	平衡预算各 3 个抽样种子；主要指标 macro-F1，辅以 accuracy、precision、recall、各类 recall 和混淆矩阵

标注预算说明：所有设置额外使用 400 句验证标签。报告必须把训练标签数与验证标签数写清楚。

阶段 2 第 3 至 5 天 跑通完整语料实验

- 提取三种模型的冻结表征并缓存；运行全部五种方法，保存原始预测、训练 ID、调参记录和收敛情况。
- 每个方法的完整训练池确定性拟合运行一次即可。一个文档划分下，四档预算各 3 次，加完整池 1 次，共计划 65 组主实验结果。
- 自动生成主结果表、平衡预算学习曲线与混淆矩阵；分别记录特征提取和分类器训练时间。

验收：全部计划结果完成并通过通用审计；表格和图中每个数字可追溯到保存的预测。

稳定性检查与错误分析

阶段 3 第 6 至 8 天 完成关键对照

文档划分稳定性

- 增加两个预先固定的文档组划分，重复主要比较；每个划分内独立调参，并尽量复用冻结表征。
- 分别报告训练子集抽样的变化和文档划分的变化。这些结果是同一语料上的内部检查，不能称为独立外部验证。

类别比例对照

- 固定总训练量为 300 句，对比每类 100 句与按自然类别比例抽取 300 句；保持验证集、测试集和调参规则相同。
- 记录实际类别数，检查当前 balanced 与 full 设置的差异是否部分来自类别构成。

验收：能说明方法排序是否稳定，以及类别比例是否影响结论；若结果不稳定，报告适用条件和变化范围。

阶段 4 第 9 至 10 天 解释错误与模型差异

- 分层抽取约 60 个案例，覆盖不同类别、方法分歧和正确或错误预测，记录抽样规则。
- 按实际错误归纳类型，如少见提示词、长句、上下文歧义和截断；两名组员独立检查部分案例，再处理分歧。
- 复核已有 10 组人工句子对，可补充少量缩写、同义表达和作用范围对照；这些材料继续用于定性诊断。

验收：有错误类别统计和代表案例，能解释简单方法与预训练表征各自的优势和限制。

解释边界：余弦相似度高不能单独证明模型无法区分否定；句级分类正确不能证明疾病状态判断正确。移除提示词后应重新核对标签，不能直接沿用原标签评价语义能力。

扩展任务的进入条件

主线完成后，再考虑混合提示词的多标签任务、表征加 linear SVM，或有可靠实体标注支持的 target-span pooling 与疾病泛化。建议第 10 天后冻结实验范围，转入复现和写作。

若时间不足，优先完成主实验、类别比例对照和错误分析，并明确披露尚未完成的跨划分检查。

最终交付与小组分工

阶段 5 第 11 至 14 天 完成材料并复现

- 完成最多 4 页的 LaTeX 期末报告，包含问题、方法、实验、分析、限制和结论；按最终课程通知制作期末 PPT。
- 由未负责主实验运行的成员，在全新环境或另一台机器上重新运行并核对最终表格。记录依赖、模型版本、数据来源及设备数值误差。
- 对报告数字重算指标，核对图表与正文；更新 README、实际执行记录、GitHub 和代码压缩包，并保存最终 commit。

建议分工

以下分工供小组确认。三位成员都应能解释任务标签、数据划分、macro-F1、冻结表征和主要结论。

成员	主要负责	交叉检查
Yuhan Sun	研究问题、协议、报告与展示	每项结论对应的实验依据
Zeyu Pan	数据划分、主实验、缓存及结果保存	重复句和数据泄漏
Jiayu Liao	错误分析、图表及全新环境复现	报告数字与运行说明

交付检查清单

交付项	通过条件
实验与分析	五种方法结果完整；预算和验证成本明确；稳定性、比例对照及错误分析有记录
报告与展示	报告不超过 4 页；PPT、正文和图表数字一致；结论不超出任务及数据支持范围
代码与复现	另一位成员按 README 可重新运行；所有报告数字可追溯；依赖和模型版本明确
引用与提交	数据、模型、外部代码及 AI 辅助有说明；PDF 和代码按课程渠道提交并确认成功

提交渠道：报告 PDF 交 Gradescope；代码邮件发送给 TA 并抄送教师，地址和期限以课程通知为准。至少一位成员确认提交成功，GitHub 上传本身不能代替课程提交。

第一步行动

先确认研究范围和建议分工，建立最终配置并改造通用审计，再启动完整语料实验。当前 full.json 的验证集未封顶，需要先调整为本计划约定的协议。

依据：课程 project.pdf、项目 EXECUTION_STATUS.md、pilot/summary.csv 及现有实验脚本。详细步骤见同目录 COMPLETION_PLAN.md。